1 INTRODUÇÃO

O câncer de pele está entre os cânceres mais frequentemente diagnosticados no mundo. O melanoma é menos frequente que outros tumores cutâneos, mas causa um número expressivo de mortes: estima-se que tenham ocorrido aproximadamente 331,6 mil novos casos e 58,6 mil mortes por melanoma cutâneo no mundo em 2022 (BRAY et al., 2024). A avaliação das lesões cutâneas começa, em geral, pela inspeção visual, podendo ser complementada pela dermatoscopia e, quando necessário, pela biópsia e pelo exame histopatológico.

Estudos anteriores indicam que redes neurais convolucionais têm potencial para classificar lesões cutâneas. Esteva et al. (2017), por exemplo, obtiveram, nas tarefas e no conjunto de avaliação definidos pelos autores, desempenho comparável ao dos dermatologistas participantes do estudo. O HAM10000 (TSCHANDL; ROSENDAHL; KITTLER, 2018), utilizado em pesquisas sobre classificação de lesões cutâneas, traz uma dificuldade: das 10.015 imagens, apenas 1.113 são de melanoma, ou seja, cerca de uma imagem de melanoma para cada oito das demais categorias. O DSCC_Net (TAHIR et al., 2023) compara seis arquiteturas de deep learning (ResNet-152, VGG-16, VGG-19, MobileNet, EfficientNetB0 e Inception-V3) na classificação multiclasse de lesões cutâneas e avalia também o efeito da técnica SMOTE-Tomek sobre o desbalanceamento de classes.

Este trabalho parte dessa dificuldade para avaliar, em um protocolo experimental controlado, como os pesos de classe e a reamostragem com aumento de dados direcionado afetam o desempenho da EfficientNetB0 na identificação de melanoma no HAM10000. A pergunta que orienta a pesquisa é: em um modelo de classificação binária (melanoma × não melanoma) baseado na arquitetura EfficientNetB0, qual estratégia de tratamento do desbalanceamento de classes apresenta o melhor equilíbrio entre sensibilidade e especificidade na identificação de melanoma no dataset HAM10000?

Para investigá-la, o trabalho propõe comparar experimentalmente, em condições controladas, estratégias de tratamento do desbalanceamento aplicadas a um modelo de classificação binária baseado na EfficientNetB0, treinado e avaliado no HAM10000. O DSCC_Net avalia o SMOTE-Tomek e compara arquiteturas diferentes em uma configuração multiclasse. Aqui, a EfficientNetB0 fica fixa, e duas estratégias, pesos de classe e reamostragem com aumento de dados direcionado, são comparadas com um *baseline* sem tratamento, em uma configuração binária de melanoma e não melanoma. Como essa configuração é diferente da do DSCC_Net, os resultados não serão tratados como diretamente comparáveis aos dessa referência, mas discutidos à luz dela.

O objetivo geral é comparar experimentalmente diferentes técnicas de tratamento do desbalanceamento de classes na detecção de melanoma em imagens dermatoscópicas, utilizando um modelo baseado na EfficientNetB0, a fim de identificar a estratégia com melhor equilíbrio entre sensibilidade e especificidade. Para isso, foram definidos os seguintes objetivos específicos:

- Caracterizar o desbalanceamento de classes presente no dataset HAM10000, com foco na proporção entre imagens de melanoma e das demais categorias.
- Estabelecer um baseline de desempenho do modelo EfficientNetB0 sem tratamento do desbalanceamento, servindo de referência para as comparações subsequentes.
- Comparar o efeito dos pesos de classe e da reamostragem com aumento de dados direcionado sobre a sensibilidade e a especificidade do modelo na identificação de melanoma.

- Identificar, entre as estratégias avaliadas, aquela que apresenta o melhor equilíbrio entre sensibilidade e especificidade, segundo um critério definido previamente.
- Discutir os resultados obtidos à luz da literatura existente sobre desbalanceamento de classes na classificação de lesões cutâneas.

Espera-se que o trabalho ajude pesquisadores e estudantes que aplicam deep learning à classificação de imagens médicas desbalanceadas, ao oferecer uma comparação entre as estratégias avaliadas e indicar qual delas apresenta o melhor equilíbrio entre sensibilidade e especificidade nas condições experimentais adotadas. Os resultados também podem servir de referência para pesquisas futuras sobre apoio à triagem de lesões cutâneas, embora este trabalho não pretenda validar uma ferramenta para uso clínico.

2 MATERIAIS E MÉTODOS

Este trabalho utilizará o conjunto de dados público HAM10000 (TSCHANDL; ROSENDAHL; KITTLER, 2018), com 10.015 imagens dermatoscópicas distribuídas em sete categorias diagnósticas. As imagens de melanoma formarão a classe positiva, e as demais categorias serão agrupadas na classe negativa, chamada "não melanoma". Essa classe negativa será heterogênea, pois reunirá diferentes tipos de lesões cutâneas.

O modelo será baseado na arquitetura EfficientNetB0 com transferência de aprendizado, implementado em Python com TensorFlow/Keras. Os experimentos serão executados em ambiente de nuvem com GPU (Google Colab ou Kaggle Notebooks). As bibliotecas pandas, Matplotlib e Seaborn serão usadas na organização dos dados e na geração dos gráficos, e a scikit-learn, no cálculo das métricas de avaliação.

O conjunto de dados será dividido de forma fixa em 70% para treinamento, 15% para validação e 15% para teste. Primeiro, será criada uma tabela com uma linha para cada lesion_id e seu rótulo binário. A divisão será estratificada no nível das lesões, de modo que todas as imagens com o mesmo lesion_id permaneçam no mesmo conjunto, o que evita que imagens de uma mesma lesão apareçam ao mesmo tempo no treinamento e no teste. A mesma divisão será usada em todos os experimentos.

As imagens serão redimensionadas para 224 × 224 pixels e preparadas de forma compatível com a implementação da EfficientNetB0 utilizada, evitando aplicar a normalização duas vezes. O limiar de classificação será 0,5 em todos os experimentos. Cada configuração será executada com três sementes aleatórias fixas (42, 123 e 2026), que controlarão a inicialização dos pesos, o embaralhamento dos dados, a reamostragem e o aumento de dados, sem alterar a divisão entre treinamento, validação e teste.

Os parâmetros de treinamento, como otimizador, taxa de aprendizado, tamanho dos lotes, número máximo de épocas e paciência da interrupção antecipada, serão definidos em testes preliminares que usem somente os conjuntos de treinamento e validação. Depois de definidos, serão mantidos iguais em todas as configurações. As etapas descritas a seguir partem dos objetivos específicos apresentados na Introdução.

2.1 ETAPA 1: CARACTERIZAÇÃO DO DESBALANCEAMENTO DE CLASSES

A primeira etapa corresponde ao objetivo de caracterizar o desbalanceamento de classes presente no HAM10000. Será feita uma análise exploratória do conjunto de dados, quantificando o número de imagens e de lesões por categoria diagnóstica e a proporção entre melanoma e não melanoma. Os metadados serão carregados com a biblioteca pandas e os registros agrupados por categoria diagnóstica e por lesion_id, para então calcular as

frequências absolutas e relativas e a razão de desbalanceamento, apresentadas em tabelas e gráficos de barras.

Para validar a etapa, serão conferidas a integridade dos metadados, a correspondência entre os registros e os arquivos de imagem e a ausência de duplicações indevidas. Também será verificado se a distribuição encontrada é compatível com os números documentados para o HAM10000, de aproximadamente 1.113 imagens de melanoma e 8.902 das demais categorias, ou seja, cerca de uma imagem de melanoma para cada oito de não melanoma. A etapa usará Python, pandas, Matplotlib, Seaborn, os metadados do HAM10000 e o ambiente Google Colab ou Kaggle Notebooks, e deve levar cerca de uma semana.

2.2 ETAPA 2: TREINAMENTO DO MODELO DE REFERÊNCIA

A segunda etapa estabelece um modelo de referência (*baseline*) da EfficientNetB0 sem tratamento do desbalanceamento. Será construído e treinado um modelo de classificação binária de melanoma e não melanoma, sem pesos de classe, reamostragem ou aumento de dados direcionado. Para isso, será usada uma EfficientNetB0 com pesos pré-treinados no ImageNet e uma camada de saída adequada à classificação binária. As imagens serão redimensionadas para 224 × 224 pixels e passarão pelo pré-processamento compatível com a implementação escolhida. O treinamento seguirá a divisão fixa por lesion_id, usará interrupção antecipada (*early stopping*) com base na perda do conjunto de validação, restaurando os melhores pesos, e será repetido com as três sementes definidas.

A etapa será considerada concluída quando as três sementes forem executadas por inteiro, sem vazamento de dados entre os conjuntos, com registro de sensibilidade (*recall*) de melanoma, especificidade, precisão, F1-score, acurácia balanceada, AUC-ROC, AUC-PR e matriz de confusão, além das curvas de perda e desempenho durante o treinamento. Serão usados Python, TensorFlow/Keras, scikit-learn, pandas e GPU do Google Colab ou Kaggle Notebooks, em cerca de duas semanas.

2.3 ETAPA 3: APLICAÇÃO DAS ESTRATÉGIAS DE TRATAMENTO DO DESBALANCEAMENTO

A terceira etapa busca comparar o efeito dos pesos de classe e da reamostragem com aumento de dados direcionado sobre a sensibilidade e a especificidade do modelo. O mesmo modelo será treinado em duas configurações independentes. Na primeira, os pesos de classe serão calculados exclusivamente com a distribuição das classes no conjunto de treinamento e usados para ponderar a função de perda, dando mais importância aos erros na classe minoritária. Essa configuração não usará reamostragem nem aumento de dados direcionado.

Na segunda configuração, as imagens de melanoma do conjunto de treinamento serão sobreamostradas (*oversampling*), com lotes de treinamento organizados de forma balanceada entre melanoma e não melanoma. Sempre que uma imagem de melanoma for amostrada novamente, poderão ser aplicadas dinamicamente rotação moderada, espelhamento e zoom leve. As imagens transformadas não serão salvas como novos arquivos. Não será aplicado aumento de dados aos conjuntos de validação e teste, que receberão apenas o redimensionamento e o pré-processamento necessários ao modelo. Alterações de brilho e cor não serão incluídas, para reduzir o número de variáveis e manter o protocolo simples.

Arquitetura, divisão dos dados, limiar de classificação e demais parâmetros de treinamento serão iguais aos do modelo de referência, e cada configuração será executada com as sementes 42, 123 e 2026. A etapa estará concluída quando as três sementes de cada configuração forem executadas, sem vazamento de dados e com registro das mesmas métricas do modelo de referência. Também será verificado se os pesos foram calculados apenas com

dados de treinamento e se a reamostragem e o aumento de dados não foram aplicados à validação nem ao teste. Os recursos são Python, TensorFlow/Keras (com pipelines de dados, pesos de classe e camadas de aumento de dados), scikit-learn e GPU do Google Colab ou Kaggle Notebooks, e o tempo estimado é de duas a três semanas.

2.4 ETAPA 4: SELEÇÃO DA MELHOR ESTRATÉGIA E AVALIAÇÃO FINAL

A quarta etapa identifica, entre as estratégias avaliadas, a que apresenta o melhor equilíbrio entre sensibilidade e especificidade. Será feita uma comparação descritiva entre o modelo de referência, o modelo com pesos de classe e o modelo com reamostragem e aumento de dados direcionado, calculando a média e o desvio-padrão das métricas nas três sementes de cada configuração. A escolha será feita exclusivamente com os resultados do conjunto de validação. Será selecionada a configuração com maior média de acurácia balanceada nas três execuções. Essa métrica corresponde à média entre sensibilidade e especificidade. Em caso de empate, será utilizada a maior média de sensibilidade para melanoma.

Registrada a decisão, o modelo de referência e a estratégia escolhida serão avaliados no conjunto de teste, que permanecerá sem consulta até esse momento, e serão reportadas as métricas das três execuções, com médias e desvios-padrão. Para validar a etapa, será documentado que a estratégia foi escolhida somente com base na validação e que o teste não foi usado para ajustar parâmetros, escolher técnicas ou alterar o critério de seleção. Serão usados Python, pandas, scikit-learn, Matplotlib e Seaborn para consolidar, comparar e visualizar os resultados, em cerca de uma semana.

2.5 ETAPA 5: DISCUSSÃO DOS RESULTADOS À LUZ DA LITERATURA

A quinta etapa discute os resultados à luz da literatura sobre desbalanceamento de classes na classificação de lesões cutâneas, com destaque para o DSCC_Net (TAHIR et al., 2023). Os resultados serão contrastados de forma qualitativa com os valores e métodos da literatura, explicitando as diferenças entre a classificação binária adotada aqui e a multiclasse do DSCC_Net, bem como as diferenças de arquiteturas, divisões dos dados e estratégias de tratamento do desbalanceamento. Por causa dessas diferenças, os resultados não serão apresentados como diretamente equivalentes.

A discussão deverá relacionar os resultados aos objetivos da pesquisa, propor possíveis explicações para o comportamento de cada estratégia, abordar as limitações do estudo e distinguir claramente a comparação contextual do uso de um trabalho anterior como referência equivalente. Para isso, serão usados artigos científicos, bases bibliográficas e as referências selecionadas para o capítulo teórico, em cerca de uma semana.

3 APRENDIZADO PROFUNDO E DESBALANCEAMENTO DE CLASSES NA CLASSIFICAÇÃO DE LESÕES CUTÂNEAS

3.1 MELANOMA E IMAGENS DERMATOSCÓPICAS

O melanoma cutâneo é uma forma de câncer de pele que, embora responda por uma parcela relativamente pequena dos casos de câncer, tem impacto relevante na mortalidade. As estimativas do GLOBOCAN 2022 indicam cerca de 331,6 mil novos casos e 58,6 mil mortes pela doença no mundo naquele ano (BRAY et al., 2024). Esses números justificam pesquisas voltadas a melhorar os métodos que auxiliam sua detecção.

A doença não se distribui de maneira uniforme entre as populações. Huang et al. (2023) encontraram diferenças nas taxas de incidência e mortalidade segundo idade, sexo e localização geográfica, com taxas mais altas na Austrália e na Nova Zelândia. Os autores

também observaram aumento da incidência global, principalmente entre pessoas com 50 anos ou mais e entre homens, enquanto a mortalidade teve tendência geral de redução. Mesmo com avanços na detecção e no tratamento, portanto, o melanoma segue sendo um problema de saúde pública.

A dermatoscopia é uma das técnicas usadas na avaliação de lesões cutâneas e apoia a diferenciação entre lesões pigmentadas benignas e malignas. As imagens que ela produz também servem para treinar redes neurais de classificação automática. Tschandl, Rosendahl e Kittler (2018) destacam que a dermatoscopia melhora a avaliação das lesões pigmentadas em comparação com a observação sem auxílio e que suas imagens podem ser usadas no desenvolvimento de métodos computacionais de classificação.

Há, portanto, concordância na literatura sobre a relevância da dermatoscopia e sobre o potencial das imagens dermatoscópicas em pesquisas com aprendizado profundo. O desempenho desses modelos, porém, depende dos dados e do protocolo de treinamento, e seus resultados não devem ser lidos como validação para uso clínico. Neste trabalho, as imagens serão usadas em um estudo computacional de classificação binária, sem pretensão de substituir a avaliação especializada. O vínculo com o problema de pesquisa está no fato de que identificar a doença depende de um modelo capaz de aprender bem os padrões da classe de maior interesse, mesmo quando ela aparece em menor quantidade nos dados de treinamento.

3.2 CONJUNTO DE DADOS HAM10000

O HAM10000 é um conjunto de dados de múltiplas fontes, formado por imagens dermatoscópicas de diferentes populações, obtidas e armazenadas por diferentes modalidades. Por causa dessa diversidade, as imagens passaram por procedimentos de organização, limpeza e padronização para serem disponibilizadas em um formato comum, voltado a pesquisas de aprendizado de máquina (TSCHANDL; ROSENDAHL; KITTLER, 2018). O conjunto tem 10.015 imagens em sete categorias diagnósticas: nevos melanocíticos, melanoma, lesões benignas semelhantes à ceratose, carcinoma basocelular, ceratoses actínicas e carcinoma intraepitelial, dermatofibroma e lesões vasculares. Mais da metade das lesões foi confirmada por exame histopatológico; as demais foram verificadas por acompanhamento clínico, consenso de especialistas ou microscopia confocal *in vivo* (TSCHANDL; ROSENDAHL; KITTLER, 2018).

Neste trabalho, as sete categorias serão reagrupadas em duas classes, melanoma e não melanoma, o que resulta em 1.113 registros de melanoma e 8.902 das demais categorias combinadas. Essa reorganização binária traz dois pontos que importam para o problema investigado. O primeiro é que a classe “não melanoma” é heterogênea: reúne desde lesões benignas, como os nevos melanocíticos, até outras neoplasias malignas, como o carcinoma basocelular, que têm em comum apenas o fato de não serem melanoma. O segundo é que algumas lesões estão representadas por mais de uma imagem dermatoscópica. Por isso, os metadados do HAM10000 trazem um identificador da lesão (lesion_id) e outro para cada imagem (image_id) (TSCHANDL; ROSENDAHL; KITTLER, 2018). Se a divisão dos dados fosse feita por imagem, registros da mesma lesão poderiam ser distribuídos entre treinamento, validação e teste. Isso causaria vazamento de dados e uma avaliação otimista demais, já que o modelo veria no treinamento características da mesma lesão que reencontraria na validação ou no teste. Para evitar o problema, a divisão será feita por lesion_id, mantendo todas as imagens de uma lesão no mesmo subconjunto.

O HAM10000 é, assim, a fonte dos dados e também a origem concreta do desbalanceamento investigado. A proporção de cerca de uma imagem de melanoma para cada

oito das demais categorias, a heterogeneidade da classe “não melanoma” e a divisão por lesão definem as condições em que as estratégias de tratamento do desbalanceamento serão comparadas.

3.3 REDES NEURAIS CONVOLUCIONAIS E TRANSFERÊNCIA DE APRENDIZADO

As redes neurais convolucionais são uma arquitetura de aprendizado profundo adequada ao processamento de imagens, porque extraem automaticamente dos dados de entrada as características relevantes para a classificação, sem depender de atributos definidos manualmente. Por meio de camadas sucessivas, essas redes produzem representações cada vez mais abstratas do conteúdo visual e identificam padrões ligados às classes que se quer distinguir. Essa capacidade fez das redes convolucionais uma abordagem central na classificação de imagens médicas (KIM et al., 2022).

Na classificação de lesões cutâneas, Esteva et al. (2017) mostraram que uma rede convolucional treinada com um grande conjunto de imagens clínicas atingiu, nas tarefas e condições de avaliação definidas pelos autores, desempenho comparável ao dos dermatologistas participantes do estudo. O resultado vale para esse estudo: indica o potencial das redes convolucionais na classificação de imagens dermatológicas, mas não prova equivalência diagnóstica em qualquer contexto clínico nem valida uma ferramenta para uso clínico.

Treinar uma rede convolucional a partir de pesos inicializados aleatoriamente costuma exigir muitos dados rotulados, o que é um problema na área médica, onde obter imagens anotadas por especialistas envolve limitações de disponibilidade e custo. O aprendizado por transferência (*transfer learning*) responde a isso ao reaproveitar o conhecimento de um modelo previamente treinado em uma tarefa ou base de origem para ajudar em uma nova tarefa relacionada (KIM et al., 2022). Modelos convolucionais pré-treinados em grandes conjuntos de imagens podem servir como extratores de características ou ser ajustados para classificar imagens médicas. Com isso, pode-se reduzir a dependência de grandes volumes de dados médicos anotados, além do custo computacional e do tempo de treinamento (KIM et al., 2022).

É esse princípio que sustenta a escolha da EfficientNetB0 pré-treinada como arquitetura-base do modelo deste estudo. Como a mesma arquitetura e as demais condições experimentais serão mantidas nas três configurações comparadas (*baseline*, pesos de classe e reamostragem com aumento de dados direcionado), será possível avaliar de forma controlada o efeito de cada estratégia sobre o equilíbrio entre sensibilidade e especificidade na identificação de melanoma, sem que variações de arquitetura interfiram nos resultados.

3.4 ARQUITETURA EFFICIENTNETB0

Um problema recorrente no desenvolvimento de redes neurais convolucionais é aumentar sua capacidade sem elevar demais o custo computacional. As estratégias convencionais costumam ampliar, de forma isolada, a profundidade da rede, sua largura ou a resolução das imagens de entrada. A família EfficientNet, proposta por Tan e Le (2019), usa um escalonamento composto: as três dimensões são ajustadas em conjunto e de forma equilibrada, por meio de coeficientes definidos de maneira sistemática.

Os autores usaram busca de arquitetura neural para desenvolver a EfficientNetB0 como configuração-base e depois ampliaram o modelo para obter as demais versões da família, de B1 a B7 (TAN; LE, 2019). Por ser a versão inicial e mais simples da família, a EfficientNetB0 combina capacidade de representação e demanda computacional moderada, aspecto relevante para experimentos feitos em nuvem com recursos limitados. Neste trabalho,

ela será usada com pesos pré-treinados no ImageNet e adaptada, por aprendizado por transferência, à classificação binária entre melanoma e não melanoma.

Miglani e Bhatia (2021) aplicaram a EfficientNetB0 à classificação de lesões cutâneas e ajustaram modelos EfficientNetB0 e ResNet-50 para as sete categorias originais do HAM10000. Nas condições experimentais dos autores, a EfficientNetB0, com menos parâmetros, atingiu AUC-ROC macro e micro de 0,93 e 0,97, contra 0,91 e 0,96 da ResNet-50. Os resultados mostram que a arquitetura pode ser aplicada ao conjunto de dados deste trabalho, mas não serão usados como referência diretamente comparável, porque o estudo foi multiclasse e seguiu um protocolo experimental diferente.

A escolha da EfficientNetB0 não parte da ideia de que ela seja superior em qualquer cenário; leva em conta sua adequação à classificação de lesões cutâneas e sua viabilidade computacional. A mesma arquitetura e os mesmos pesos pré-treinados no ImageNet serão usados nas três configurações (*baseline*, pesos de classe e reamostragem com aumento de dados direcionado), assim como a mesma divisão dos dados, as mesmas sementes aleatórias e os mesmos hiperparâmetros, exceto pelo tratamento do desbalanceamento de cada configuração. Assim, as diferenças nas métricas poderão ser atribuídas principalmente às estratégias avaliadas, sem a arquitetura como fator adicional de variação.

3.5 DESBALANCEAMENTO DE CLASSES E MÉTRICAS DE AVALIAÇÃO

O desbalanceamento de classes ocorre quando as categorias de um conjunto de dados têm quantidades muito diferentes de exemplos. Na classificação binária, a classe com menos registros é chamada minoritária e, com frequência, corresponde ao evento de maior interesse. Na área médica, por exemplo, os casos positivos de uma doença podem ser menos frequentes que os negativos. Modelos treinados sem considerar essa diferença podem favorecer a classe majoritária e ter mais dificuldade para reconhecer a minoritária (JOHNSON; KHOSHGOFTAAR, 2019).

A distribuição desigual também afeta a leitura das métricas. No HAM10000 reorganizado para este trabalho, 8.902 das 10.015 imagens são de não melanoma. Um classificador que previsse “não melanoma” para todas as imagens teria cerca de 88,9% de acurácia sem identificar nenhum melanoma. Esse exemplo mostra que uma acurácia alta pode esconder mau desempenho na classe minoritária, e por isso ela não deve ser usada isoladamente para avaliar classificadores treinados com dados desbalanceados (JOHNSON; KHOSHGOFTAAR, 2019).

Neste estudo, o melanoma será a classe positiva. A matriz de confusão mostrará verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos. A sensibilidade, também chamada de *recall*, indicará a proporção de melanomas corretamente identificados, e a especificidade, a proporção de imagens de não melanoma corretamente classificadas. A precisão indicará quantas das imagens classificadas como melanoma realmente pertencem a essa classe, e a medida F1 resumirá precisão e sensibilidade por meio de sua média harmônica. A acurácia balanceada, média entre sensibilidade e especificidade, dá o mesmo peso ao desempenho nas duas classes.

Também serão usadas a área sob a curva ROC (AUC-ROC) e a área sob a curva precisão-*recall* (AUC-PR), que avaliam o classificador em diferentes limiares de decisão. A curva ROC relaciona a taxa de verdadeiros positivos à de falsos positivos; a curva precisão-*recall* mostra a relação entre a capacidade de encontrar casos positivos e a confiabilidade das previsões positivas. Ao analisar classificadores de imagens médicas em cenários desbalanceados, Mosquera et al. (2024) observaram que métricas dominadas pela classe majoritária podem esconder desempenho insuficiente na classe minoritária e

recomendaram métricas complementares, entre elas a AUC-PR. O estudo usa radiografias de tórax, mas suas considerações podem ser aplicadas à avaliação de classificadores de imagens médicas desbalanceadas em geral.

No protocolo deste trabalho, precisão, sensibilidade, especificidade, medida F1, acurácia balanceada e matriz de confusão serão calculadas com limiar de classificação de 0,5. A AUC-ROC e a AUC-PR serão calculadas a partir das probabilidades do modelo, considerando diferentes limiares. Para cada configuração, serão apresentadas a média e o desvio-padrão das métricas das três sementes. A estratégia será selecionada exclusivamente no conjunto de validação, pela maior média de acurácia balanceada entre as três sementes, com a média do *recall* de melanoma como critério de desempate. Esse critério é uma decisão metodológica deste trabalho e permite avaliar diretamente o equilíbrio entre sensibilidade e especificidade proposto na pergunta de pesquisa.

3.6 ESTRATÉGIAS DE TRATAMENTO DO DESBALANCEAMENTO E ESTUDOS RELACIONADOS

As estratégias para tratar o desbalanceamento podem atuar sobre os dados, sobre o algoritmo de aprendizagem ou combinar as duas frentes. Os métodos aplicados aos dados mudam a distribuição das classes, por exemplo por sobreamostragem ou subamostragem. Os métodos algorítmicos alteram o processo de aprendizagem para dar mais importância aos exemplos da classe minoritária. Há ainda estratégias híbridas, que reúnem procedimentos dos dois grupos (JOHNSON; KHOSHGOFTAAR, 2019). Neste trabalho serão avaliadas uma abordagem algorítmica, os pesos de classe, e uma aplicada aos dados, a reamostragem com aumento de dados direcionado.

Os pesos de classe alteram a contribuição de cada categoria para a função de perda durante o treinamento. Erros na classe minoritária recebem peso maior, o que leva o modelo a dar mais atenção aos casos menos representados sem mudar a quantidade de imagens do conjunto de treino. A implementação é relativamente simples e todas as amostras são preservadas, mas é preciso observar o efeito sobre as duas métricas ao mesmo tempo: a sensibilidade ao melanoma pode subir à custa da especificidade, se o modelo passar a classificar mais imagens de não melanoma como positivas.

A sobreamostragem (*oversampling*) aumenta a frequência com que exemplos da classe minoritária são apresentados ao modelo durante o treinamento. Repetir as mesmas imagens sem alteração, porém, pode favorecer a memorização. Para reduzir esse risco, a segunda estratégia deste trabalho combinará a reamostragem das imagens de melanoma com transformações geométricas aplicadas dinamicamente, como rotação moderada, espelhamento e zoom leve, de modo que cada reapresentação possa receber uma transformação aleatória. O procedimento será feito apenas no conjunto de treino e depois da divisão por lesion_id, para que versões derivadas da mesma lesão não apareçam na validação ou no teste.

Na classificação de lesões cutâneas, Gessert et al. (2020) compararam sobreamostragem, formação de lotes balanceados e ponderação da perda por classe em conjuntos multiclasse, e propuseram ainda uma ponderação orientada pelo método de confirmação diagnóstica. Os autores observaram que o balanceamento contribuiu para melhorar a sensibilidade média dos modelos. Tahir et al. (2023), por sua vez, desenvolveram o DSCC_Net e usaram a técnica híbrida SMOTE-Tomek para tratar o desbalanceamento, comparando o modelo proposto com seis redes conhecidas, entre elas a EfficientNetB0; os resultados com e sem SMOTE-Tomek mostraram diferenças expressivas no desempenho do modelo proposto. Esses estudos indicam que tratar o desbalanceamento faz diferença, mas

usam configurações multiclasse, arquiteturas e protocolos diferentes dos deste trabalho, o que impede a comparação direta dos valores.

Diante dessas diferenças, este trabalho fará uma comparação controlada entre três configurações da mesma EfficientNetB0: um modelo de referência sem tratamento do desbalanceamento, um com pesos de classe e um com reamostragem associada ao aumento de dados direcionado. A divisão dos dados, as sementes e os demais hiperparâmetros serão mantidos, variando apenas a estratégia avaliada. Isso permitirá analisar qual alternativa apresenta o melhor equilíbrio entre sensibilidade e especificidade na identificação de melanoma, sem afirmar que ela seja superior em outros conjuntos de dados ou contextos.

REFERÊNCIAS

BRAY, F. et al. Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. **CA: A Cancer Journal for Clinicians**, v. 74, n. 3, p. 229–263, 2024. DOI: https://doi.org/10.3322/caac.21834.

ESTEVA, A. et al. Dermatologist-level classification of skin cancer with deep neural networks. **Nature**, v. 542, n. 7639, p. 115–118, 2017. DOI: https://doi.org/10.1038/nature21056.

GESSERT, N. et al. Skin Lesion Classification Using CNNs With Patch-Based Attention and Diagnosis-Guided Loss Weighting. **IEEE Transactions on Biomedical Engineering**, v. 67, n. 2, p. 495–503, 2020. DOI: https://doi.org/10.1109/TBME.2019.2915839.

HUANG, J. et al. Global Incidence, Mortality, Risk Factors and Trends of Melanoma: A Systematic Analysis of Registries. **American Journal of Clinical Dermatology**, v. 24, n. 6, p. 965–975, 2023. DOI: https://doi.org/10.1007/s40257-023-00795-3.

JOHNSON, J. M.; KHOSHGOFTAAR, T. M. Survey on deep learning with class imbalance. **Journal of Big Data**, v. 6, art. 27, 2019. DOI: https://doi.org/10.1186/s40537-019-0192-5.

KIM, H. E. et al. Transfer learning for medical image classification: a literature review. **BMC Medical Imaging**, v. 22, art. 69, 2022. DOI: https://doi.org/10.1186/s12880-022-00793-7.

MIGLANI, V.; BHATIA, M. P. S. Skin Lesion Classification: A Transfer Learning Approach Using EfficientNets. In: HASSANIEN, A. E.; BHATNAGAR, R.; DARWISH, A. (ed.). **Advanced Machine Learning Technologies and Applications**. Singapore: Springer, 2021. p. 315–324. (Advances in Intelligent Systems and Computing, v. 1141). DOI: https://doi.org/10.1007/978-981-15-3383-9_29.

MOSQUERA, C. et al. Class imbalance on medical image classification: towards better evaluation practices for discrimination and calibration performance. **European Radiology**, v. 34, n. 12, p. 7895–7903, 2024. DOI: https://doi.org/10.1007/s00330-024-10834-0.

TAHIR, M. et al. DSCC_Net: Multi-Classification Deep Learning Models for Diagnosing of Skin Cancer Using Dermoscopic Images. **Cancers**, v. 15, n. 7, art. 2179, 2023. DOI: https://doi.org/10.3390/cancers15072179.

TAN, M.; LE, Q. V. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 36., 2019, Long Beach. **Proceedings [...]**. [S. l.]: PMLR, 2019. v. 97, p. 6105–6114. Disponível em: https://proceedings.mlr.press/v97/tan19a.html. Acesso em: 16 out. 2026.

TSCHANDL, P.; ROSENDAHL, C.; KITTLER, H. The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. **Scientific Data**, v. 5, art. 180161, 2018. DOI: https://doi.org/10.1038/sdata.2018.161.